Laboratorio 6: Escalado y balanceo de carga de la arquitectura

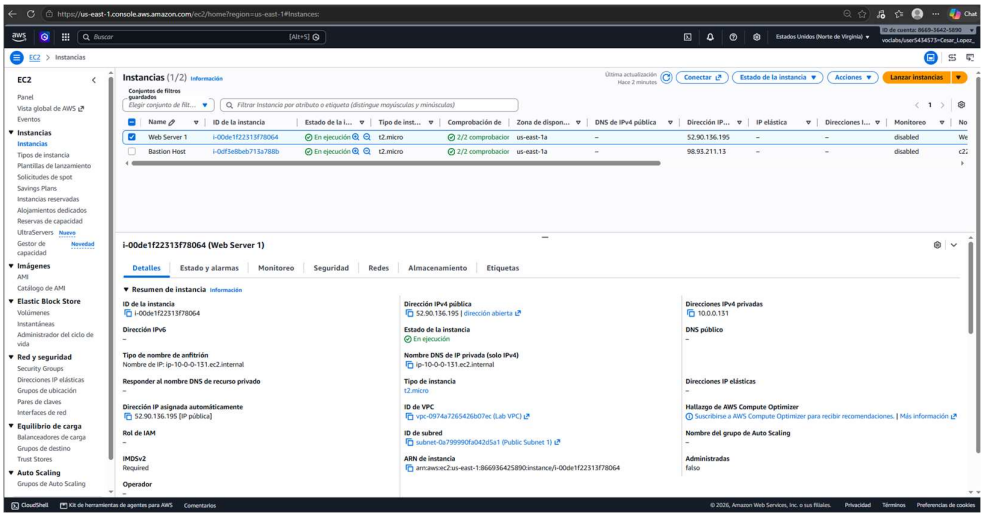
Apellidos y Nombres: López Arteaga, Cesar Omar

Codigo: 20215508C

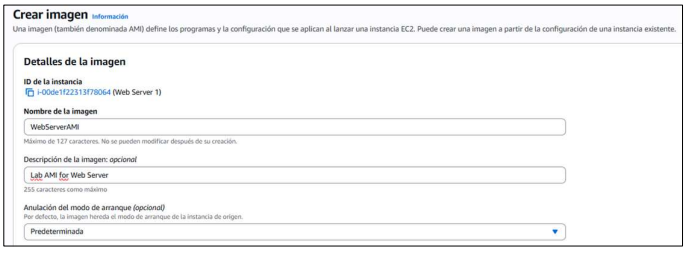
Tarea 1: crear una AMI para Auto Scaling

En esta tarea, creará una AMI a partir del *Web Server 1* (Servidor web 1) existente. Esto permitirá guardar el contenido del disco de arranque para que se puedan lanzar instancias nuevas con un contenido idéntico.

- En la **Consola de administración de AWS**, en el cuadro de búsqueda junto a **Servicios** , busque y seleccione **EC2**.
- En el panel de navegación izquierdo, elija **Instancias**.
- Espere hasta que en **Comprobaciones de estado** de **Web Server 1** (Servidor web 1) se muestre el mensaje *2/2 comprobaciones superadas*. Si es necesario, seleccione para actualizar el estado.
- Seleccione **Web Server 1** (Servidor web 1).

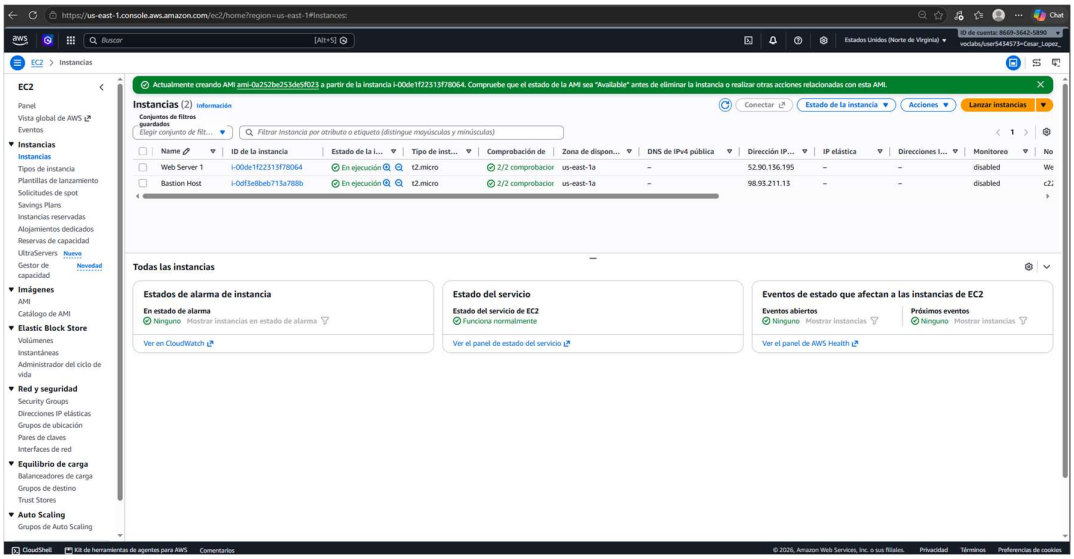


- En el menú **Acciones** , seleccione **Imagen y plantillas** > **Crear imagen** y configure lo siguiente:
    - **Nombre de la imagen:** WebServerAMI
    - **Descripción de la imagen:** Lab AMI for Web Server



- Seleccione **Crear imagen**

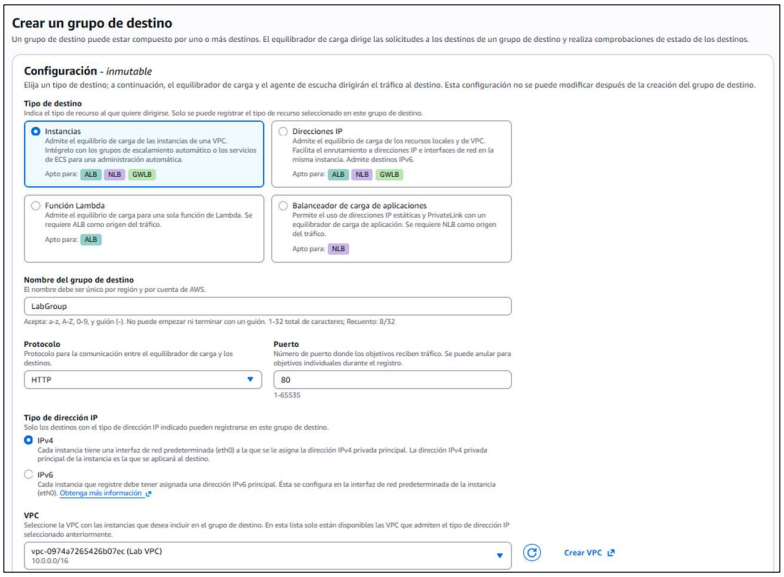
En un anuncio de confirmación, se muestra el **ID de AMI** de la nueva AMI.



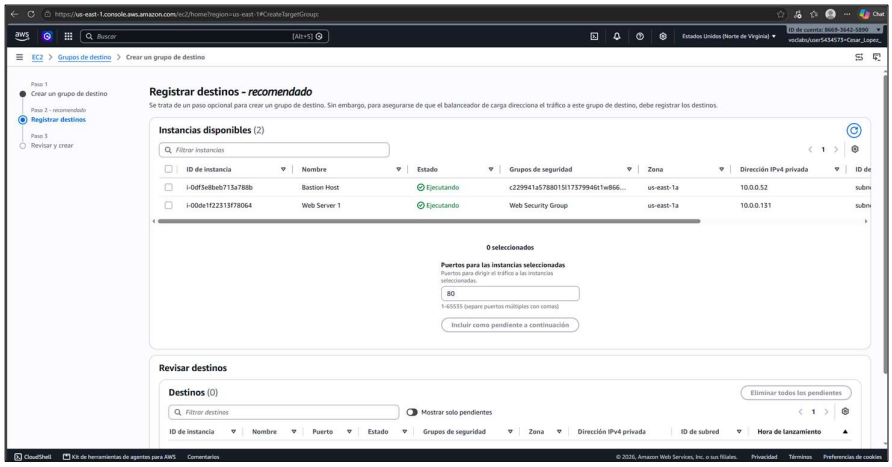
Tarea 2: crear un equilibrador de carga

En esta tarea, primero creará un grupo de destino y, luego, un equilibrador de carga para equilibrar el tráfico en varias instancias de EC2 y zonas de disponibilidad.

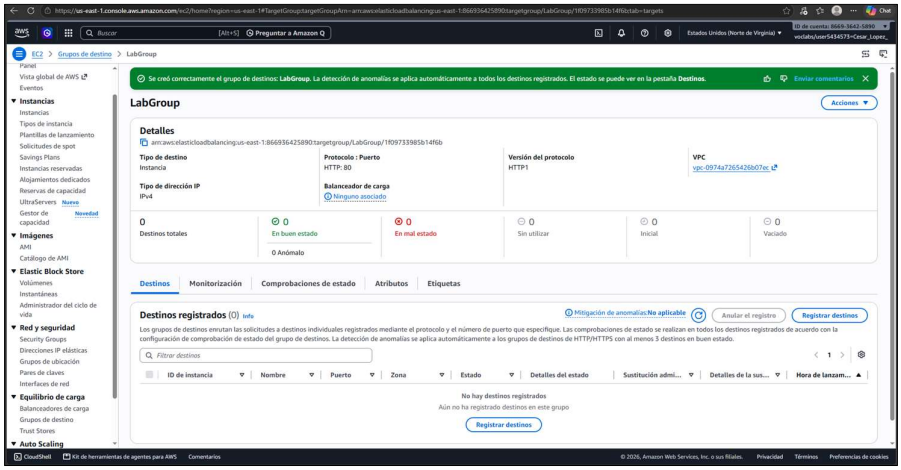
- En el panel de navegación izquierdo, elija **Grupos de destino**.
    - Elija **Crear grupo de destino**
    - Elija un tipo de destino: **Instancias**
    - **Nombre del grupo de destino**, ingrese: LabGroup
    - Seleccione **Lab VPC** (VPC del laboratorio) en el menú desplegable **VPC**.



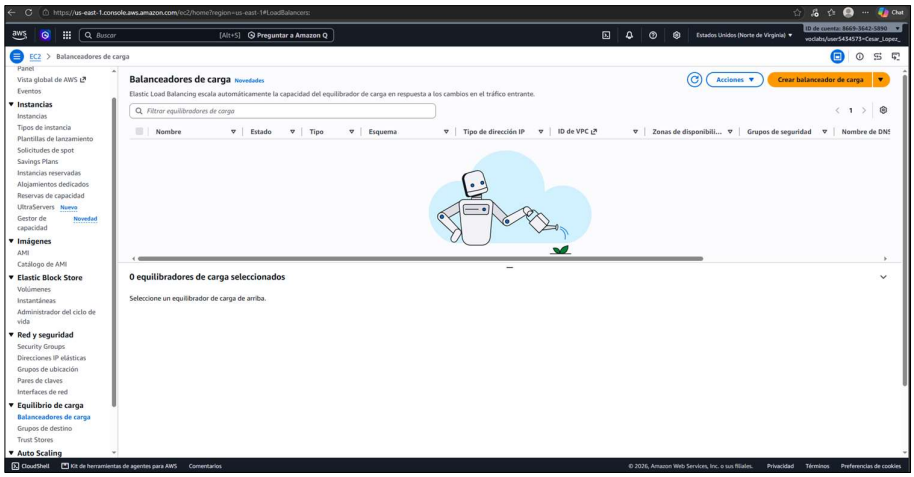
- Elija **Siguiente**. Aparece la pantalla **Registrar destinos**.



- Revise la configuración y elija **Crear grupo de destino**

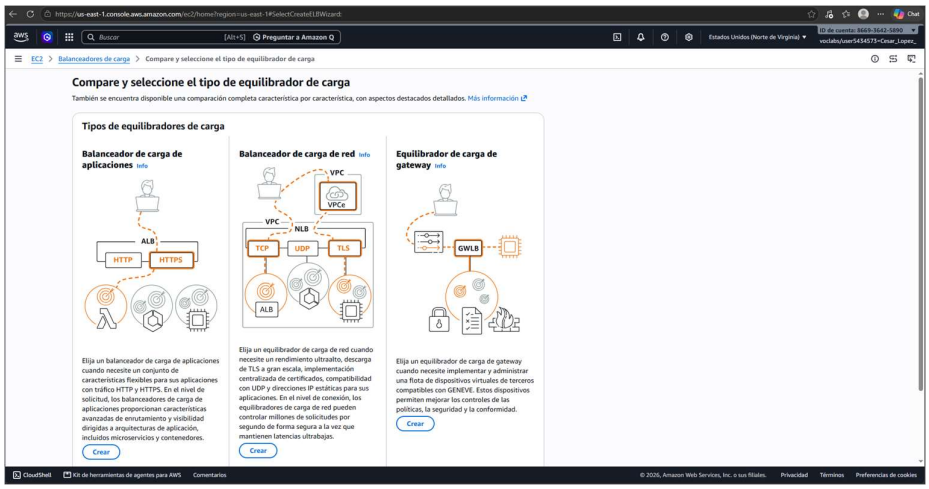


- En el panel de navegación izquierdo, elija **Balanceadores de carga**.

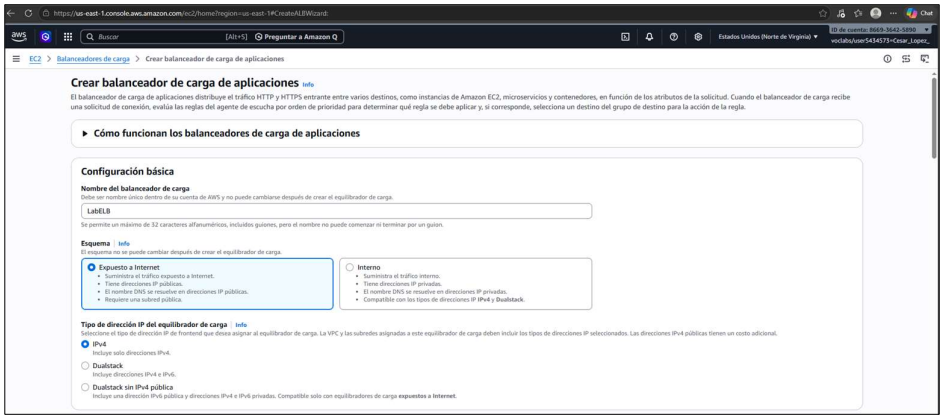


- En la parte superior de la pantalla, seleccione **Crear balanceador de carga**.

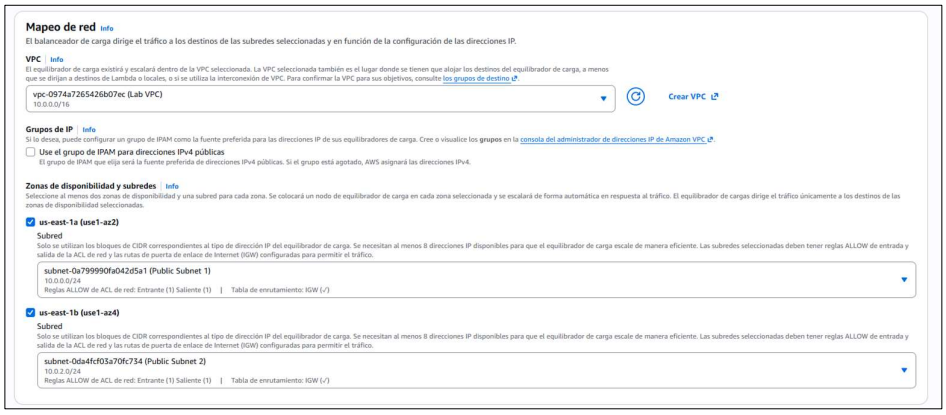
A continuación, se muestran diferentes tipos de equilibradores de carga. Utilizará un *equilibrador de carga de aplicación* que funciona a nivel de solicitud (capa 7), a través del cual se dirige el tráfico a los destinos (instancias de EC2, contenedores, direcciones IP y funciones de Lambda) según el contenido de la solicitud.



- En **Equilibrador de carga de aplicación**, seleccione **Crear**
- En **Nombre del balanceador de carga**, ingrese: LabELB

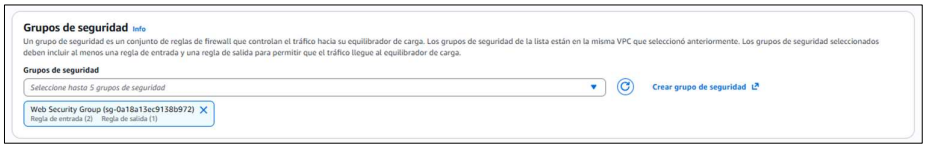


- Desplácese a la sección **Mapeo de red**, luego, haga lo siguiente:
    - En **VPC**, elija **Lab VPC** (VPC de laboratorio).
    - Elija la zona de disponibilidad que aparece en **primer** lugar, luego, seleccione **Subred pública 1** en el menú desplegable Subred que se muestra debajo de ella.
    - Elija la zona de disponibilidad que aparece en **segundo** lugar, luego, seleccione **Subred pública 2** en el menú desplegable Subred que se muestra debajo de ella.

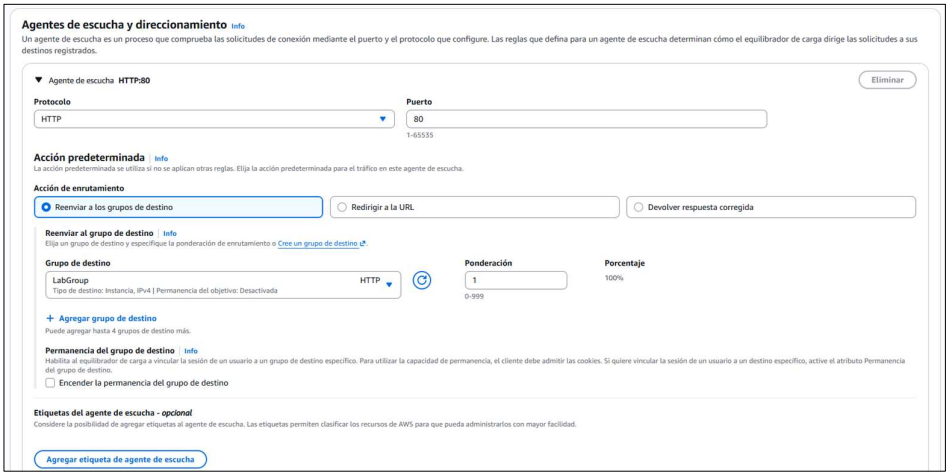


Ahora debería tener dos subredes seleccionadas: la **Subred pública 1** y la **Subred pública 2**.

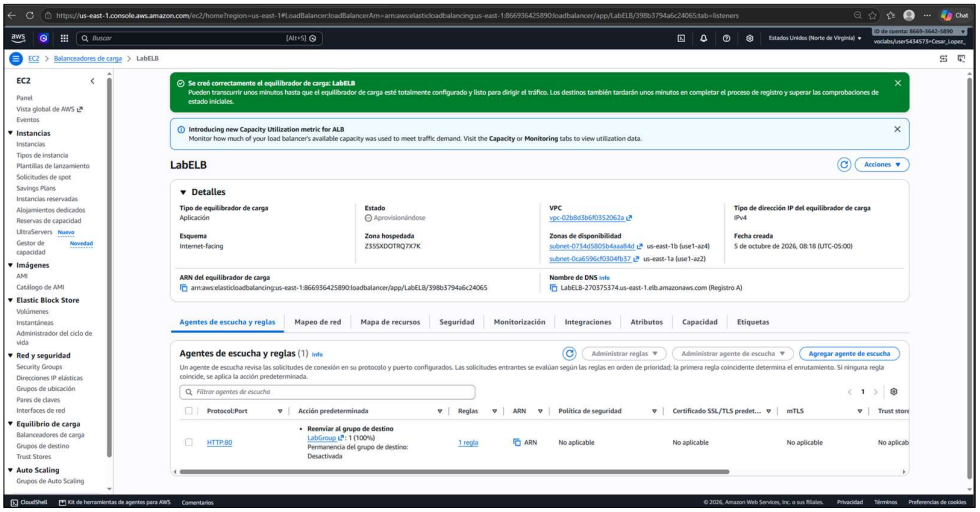
- En la sección **Grupos de seguridad**, configure lo siguiente:
    - Elija el menú desplegable Grupos de seguridad y seleccione **Web Security Group** (Grupo de seguridad web).



- Para la fila del agente de escucha HTTP:80, configure la acción Predeterminada en **LabGroup**.



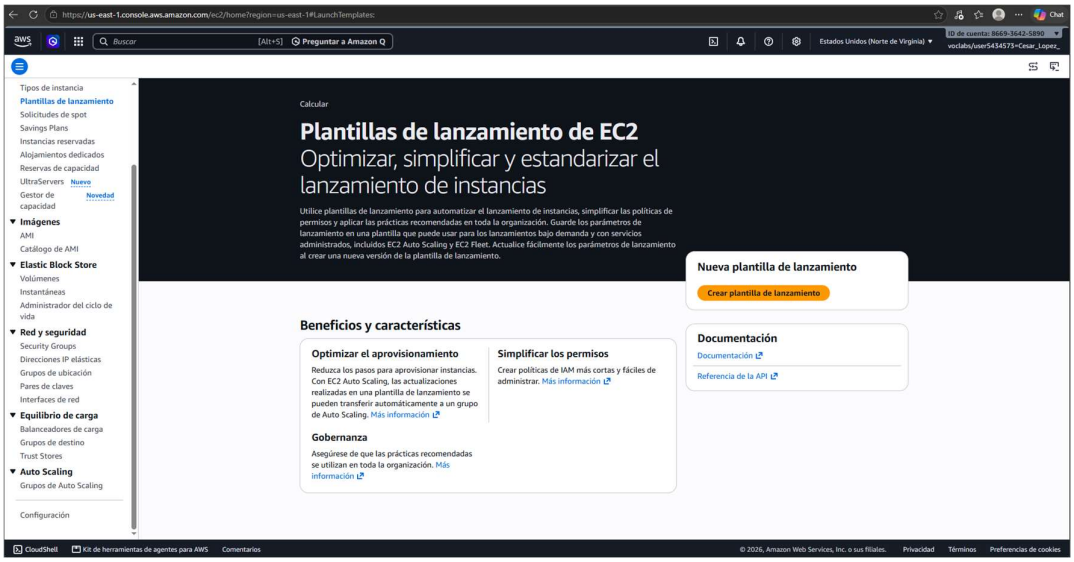
- Desplácese hasta la parte inferior y seleccione **Crear balanceador de carga**
    - Elija **Ver el balanceador de carga**



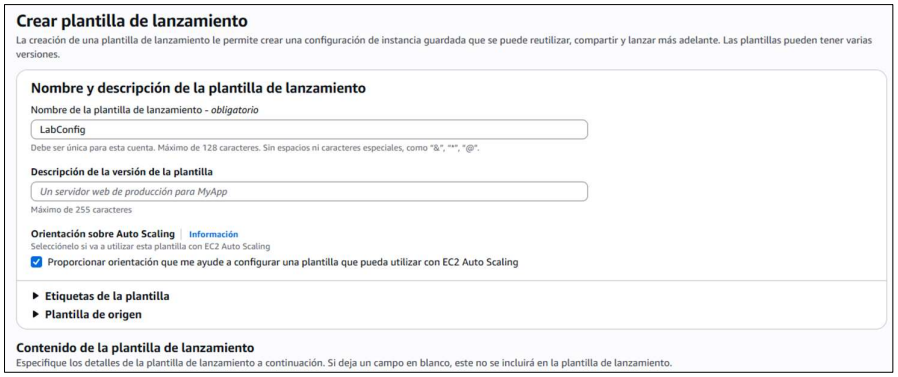
Tarea 3: crear una plantilla de lanzamiento y un grupo de escalado automático

En esta tarea, creará una *plantilla de lanzamiento* para el grupo de Auto Scaling. Una plantilla de lanzamiento consiste en una plantilla que utiliza un grupo de escalado automático para lanzar instancias de EC2. Cuando se crea una plantilla de lanzamiento, se especifica la información de las instancias, tales como la AMI, el tipo de instancia, un par de claves y un grupo de seguridad.

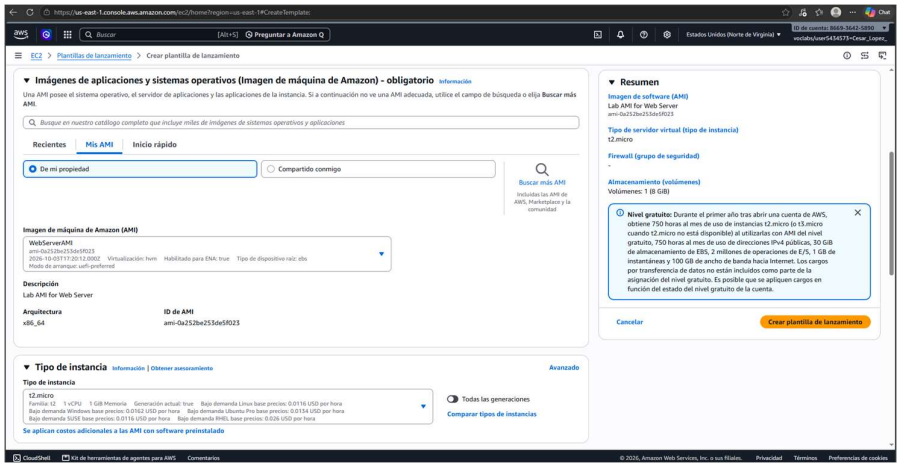
- En el panel de navegación izquierdo, elija **Plantillas de lanzamiento**.



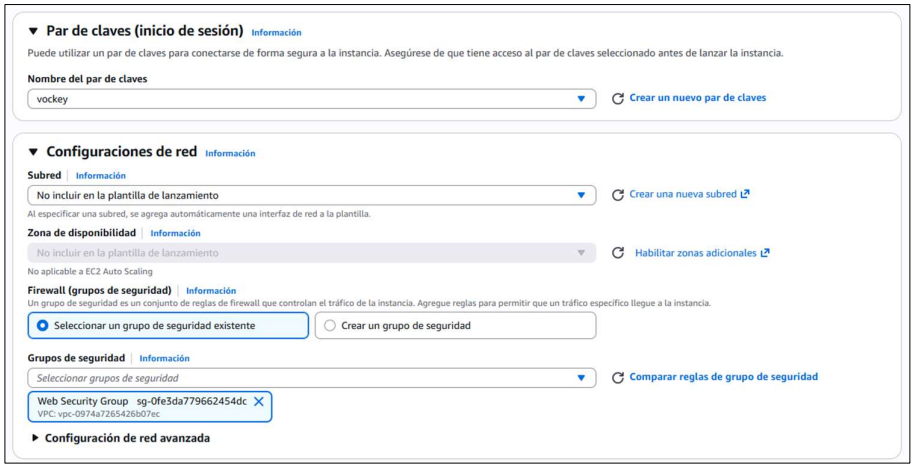
- Elija **Crear plantilla de lanzamiento**
- Configure los ajustes de la plantilla de lanzamiento y créela:
    - **Nombre de la plantilla de lanzamiento:** LabConfig
    - En **Orientación sobre Auto Scaling**, selecciónelo.



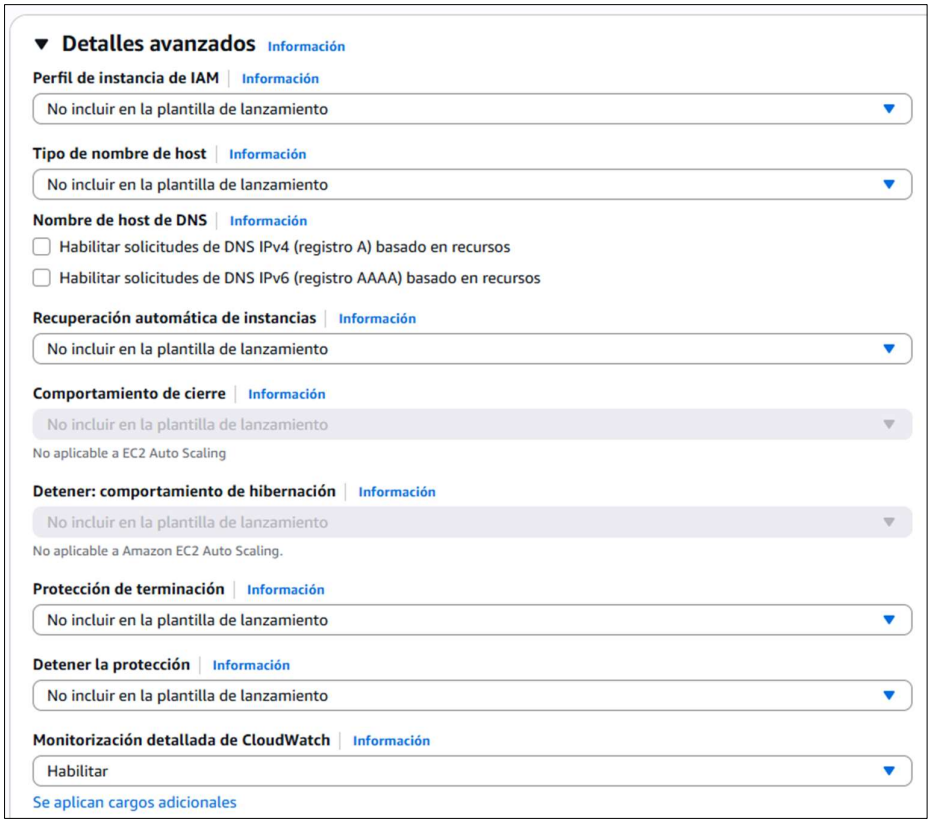
    - En el área Imágenes de aplicaciones y sistemas operativos (Imagen de máquina de Amazon), seleccione *Mis AMI*.
    - **Imagen de máquina de Amazon (AMI)**: elija *Web Server AMI* (AMI de servidor web)
    - **Tipo de instancia:** elija *t2.micro*



- **Nombre del par de claves**: elija *vockey*
- **Firewall (grupos de seguridad)**: elija *Seleccionar un grupo de seguridad existente*.
- **Grupos de seguridad**: elija *Web Security Group* (Grupo de seguridad web).



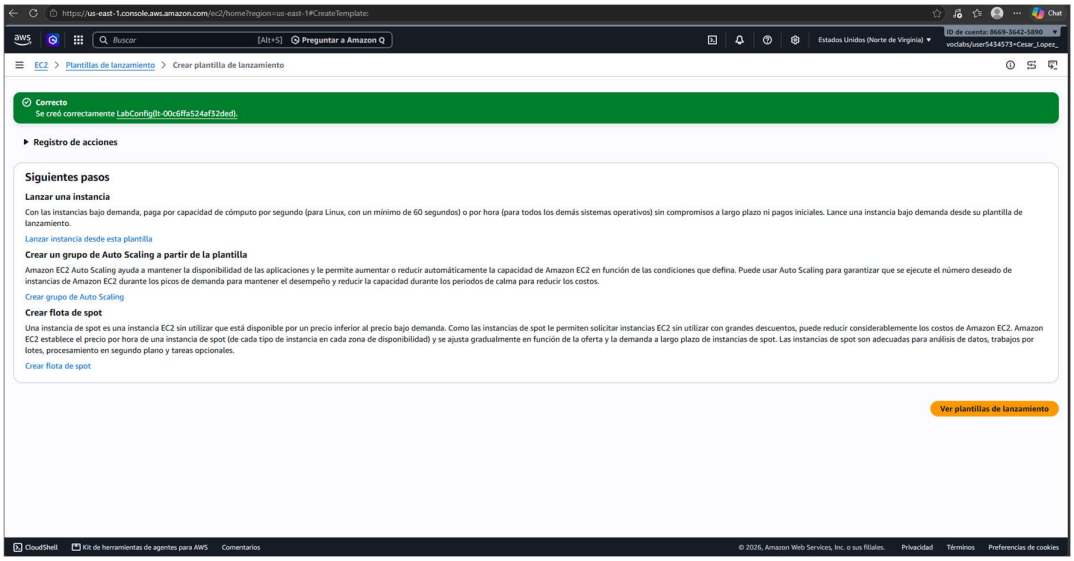
- Desplácese hacia abajo hasta la sección **Detalles avanzados** y expándala.
- Desplácese hacia abajo hasta la configuración de **Monitorización detallada de CloudWatch**. Seleccione *Habilitar*



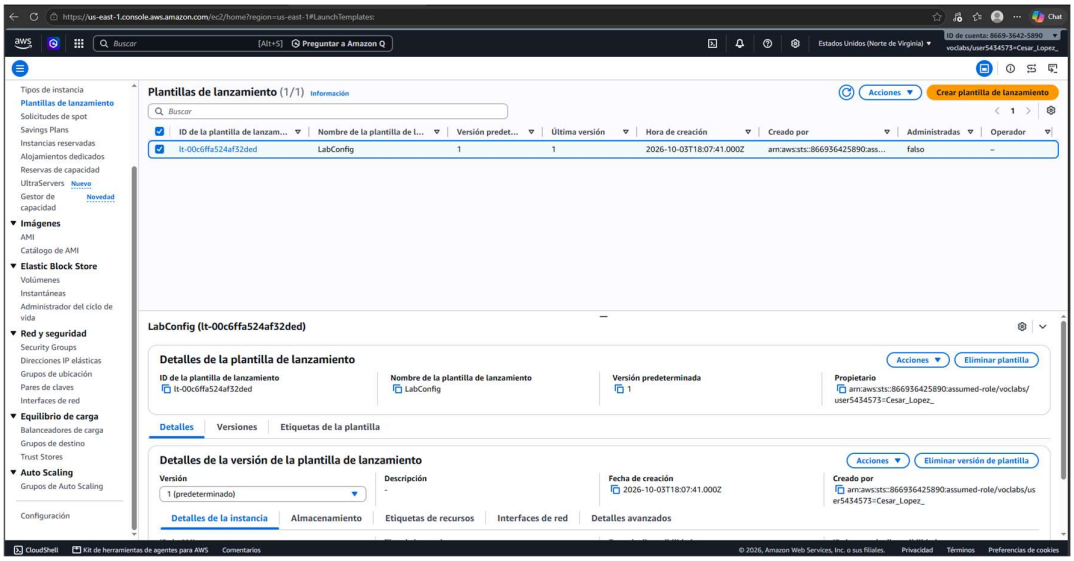
Nota: Esto permitirá que Auto Scaling reaccione rápidamente a los cambios de utilización.

- Elija **Crear plantilla de lanzamiento**

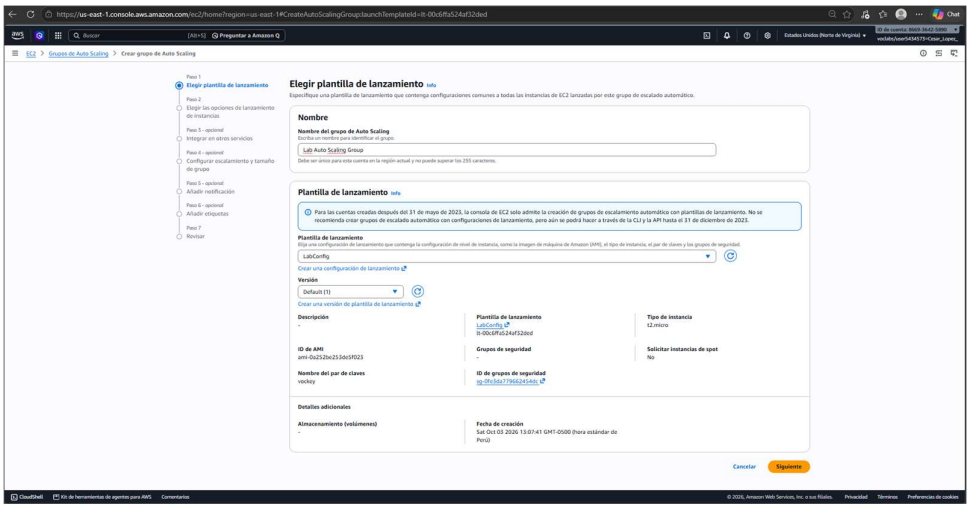
A continuación, creará un grupo de escalado automático que utilice esta plantilla de lanzamiento.



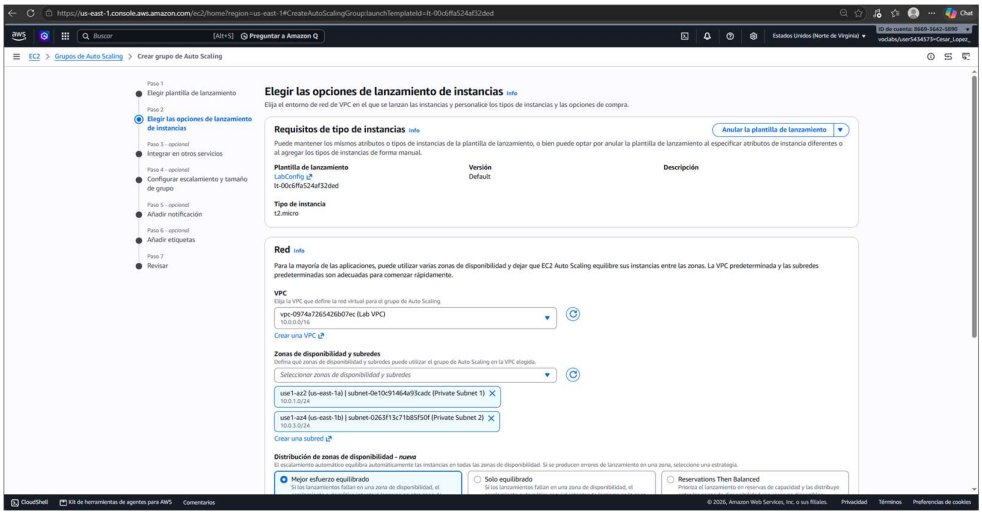
- En el cuadro de diálogo de Listo, elija la plantilla de lanzamiento **LabConfig**.



- En el menú **Acciones** , seleccione *Crear grupo de Auto Scaling*
- Configure los detalles en el Paso 1 (Elegir la plantilla o la configuración de lanzamiento):
    - **Nombre del grupo de Auto Scaling:** Lab Auto Scaling Group
    - **Lanzar plantilla**: confirme que esté seleccionada la plantilla *LabConfig* que acaba de crear.
    - Elija **Siguiente**



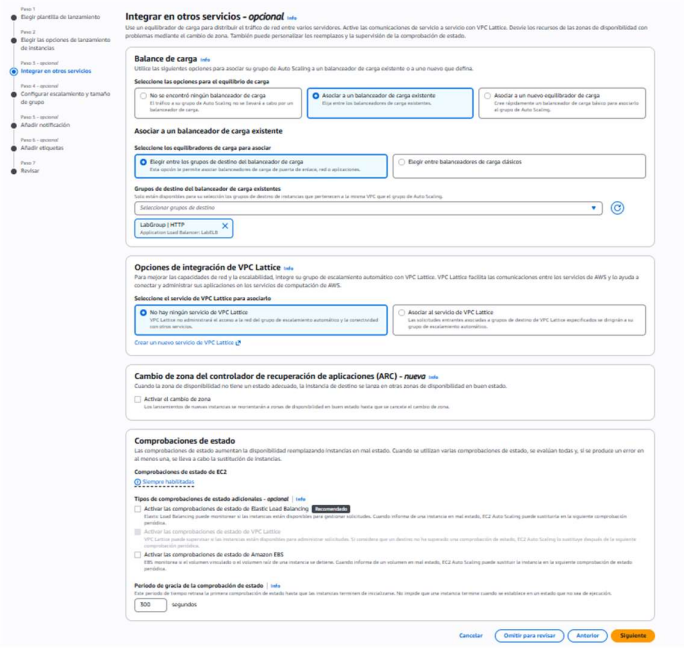
- Configure los detalles en el Paso 2 (Elegir las opciones de lanzamiento de la instancia):
    - **VPC**: seleccione *Lab VPC* (VPC de laboratorio).
    - **Zonas de disponibilidad y subredes**: elija *Subred privada 1* y, a continuación, seleccione *Subred privada 2*.
    - Elija **Siguiente**



- Configure los detalles en el Paso 3 (Configurar opciones avanzadas):
    - Seleccione **Asociar a un balanceador de carga existente**
        1. **Grupos de destino del balanceador de carga existentes**: seleccione *LabGroup*.
    - En el panel **Configuración adicional**:
        1. Seleccione **Enable group metrics collection within CloudWatch** (Habilitar la recopilación de métricas de grupo en CloudWatch)

De este modo, se capturarán métricas en intervalos de 1 minuto, lo que permite que Auto Scaling reaccione rápidamente a los patrones de uso cambiantes.

- Elija **Siguiente**

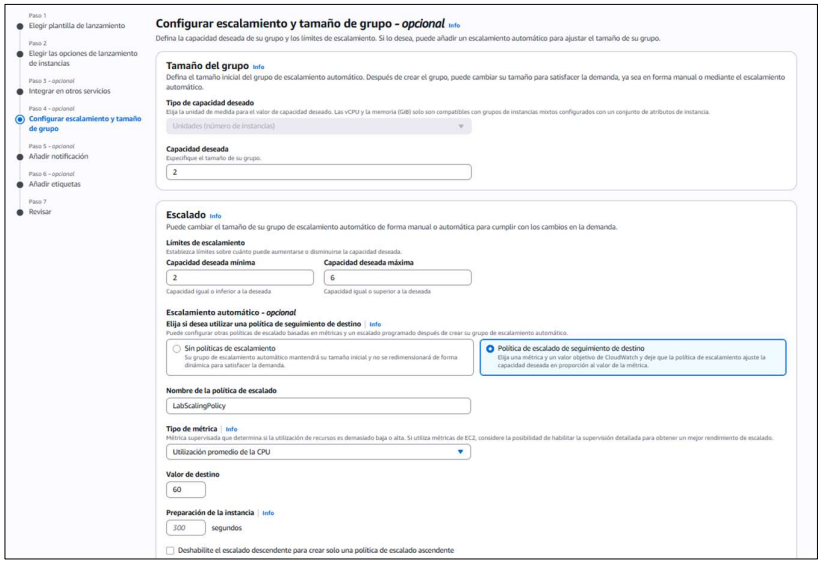


- Configure los detalles en el Paso 4 (Configurar políticas de escalado y tamaño de grupo, opcional):
    - En **Tamaño de grupo**, configure lo siguiente:
        1. **Capacidad deseada:** 2
        2. **Capacidad mínima:** 2
        3. **Capacidad máxima:** 6

Esto permite que Auto Scaling agregue o elimine instancias automáticamente, y siempre mantenga entre dos y seis instancias en ejecución.

- En **Políticas de escalado**, seleccione *Política de escalado de seguimiento de destino* y configure lo siguiente:

1. **Nombre de la política de escalado:** LabScalingPolicy
2. **Tipo de métrica:** *utilización de CPU promedio*
3. **Valor de destino:** 60



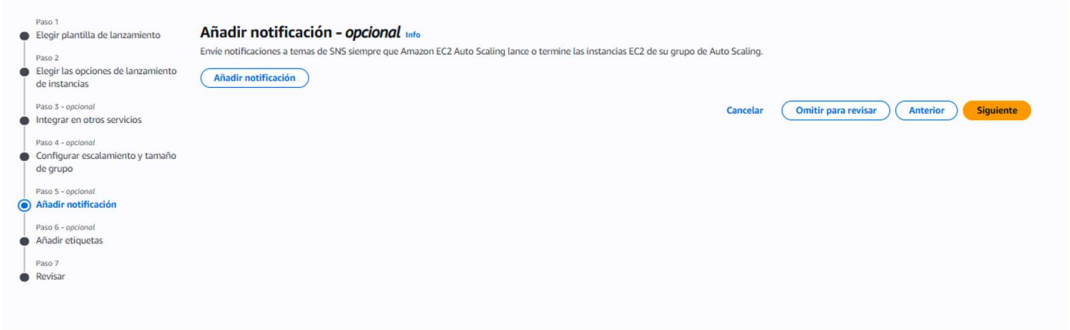
De este modo, se le indica a Auto Scaling que mantenga un uso *promedio* de CPU del 60 % *en todas las instancias*. Auto Scaling aumenta o reduce la capacidad de forma automática, según sea necesario, para mantener la métrica en el valor de destino especificado o en un valor próximo. Se ajusta a las fluctuaciones de la métrica debido a un patrón de carga fluctuante.

- Elija **Siguiente**

- Configure los detalles en el Paso 5 (Agregar notificaciones, opcional):

Auto Scaling puede enviar una notificación cuando se produce un evento de escalado. Deberá utilizar los valores predeterminados.

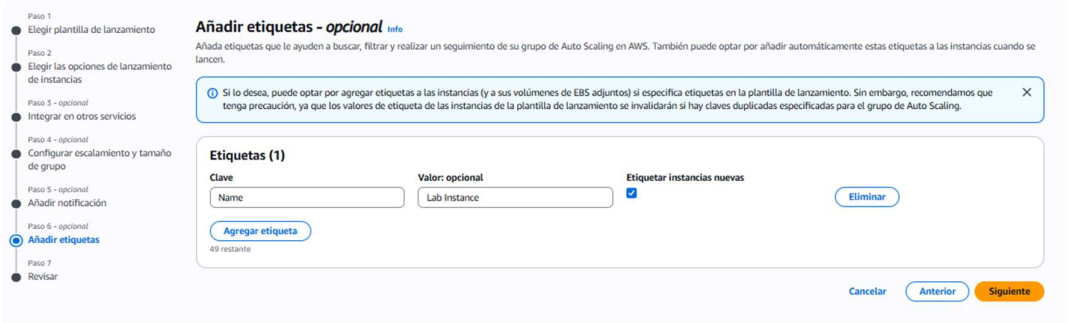
- Elija **Siguiente**



- Configure los detalles en el Paso 6 (Agregar etiquetas, opcional):

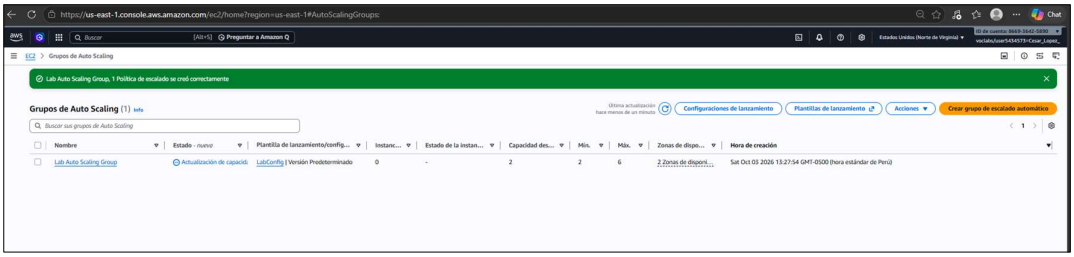
Las etiquetas que se apliquen al grupo de escalado automático se propagarán automáticamente a las instancias que se lancen.

- Elija **Agregar etiqueta** y configure lo siguiente:
    1. **Clave:** Name
    2. **Valor:** Lab Instance
- Elija **Siguiente**



- Configure los detalles en el Paso 6 (Revisar):
    - Revise los detalles de tu grupo de escalado automático
    - Seleccione **Crear grupo de Auto Scaling**

En el grupo de Auto Scaling, se mostrará inicialmente un recuento de instancias igual a cero, pero se iniciarán instancias nuevas para alcanzar el recuento **deseado** de 2 instancias.

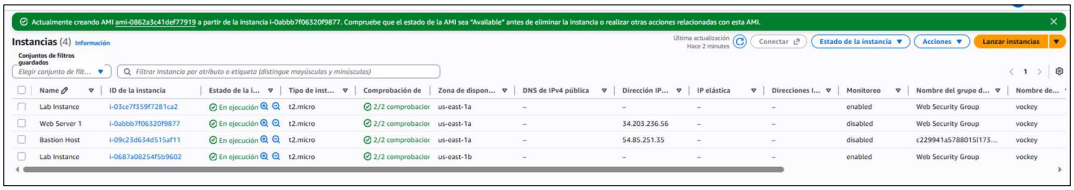


Tarea 4: comprobar el funcionamiento del balanceo de carga

En esta tarea, verificará el correcto funcionamiento del balanceo de carga.

33. En el panel de navegación izquierdo, elija **Instancias**.

Verá dos instancias nuevas llamadas **Lab Instance** (Instancia de laboratorio). Auto Scaling las ha iniciado.

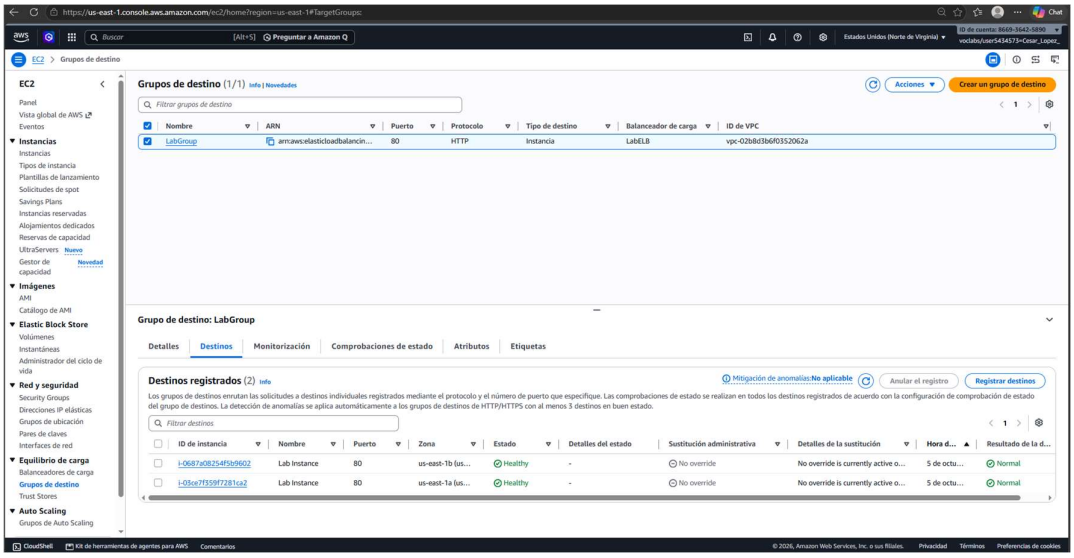


- En el panel de navegación izquierdo, elija **Grupos de destino**.
- Seleccione *LabGroup*
- Elija la pestaña **Destinos**.

En el grupo de destino deben aparecer dos instancias de destino denominadas instancia de laboratorio.

- Espere a que el **Estado** de ambas instancias cambie a *en buen estado*.

Ahora, puede acceder al grupo de escalado automático mediante el equilibrador de carga.



- En el panel de navegación izquierdo, elija **Balanceadores de carga**.
- Seleccione el equilibrador de carga *LabELB*.

En el panel Detalles, copie el **Nombre de DNS** del equilibrador de carga y asegúrese de omitir "(A Record)" (Registro A). Debería ser similar a: *LabELB-1998580470.us-west-2.elb.amazonaws.com*

- Abra una pestaña nueva en el navegador web, pegue el nombre de DNS que acaba de copiar y presione la Enter (Intro).



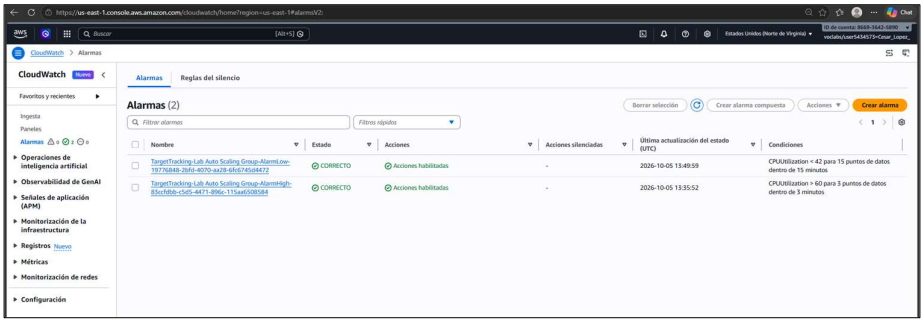
La aplicación debe aparecer en el navegador. Esto indica que el Balanceador de carga recibió la solicitud, la envió a una de las instancias EC2 y luego arrojó el resultado.

Tarea 5: realizar pruebas de Auto Scaling

Ha creado un grupo de escalado automático con un mínimo de dos instancias y un máximo de seis. En el momento hay dos instancias en ejecución porque dos es el tamaño mínimo y el grupo no está sujeto a ninguna carga. Ahora, aumentará la carga para que Auto Scaling agregue instancias adicionales.

- Regrese a la Consola de administración de AWS, pero no cierre la pestaña de la aplicación, ya que pronto deberá volver a ella.
- En el cuadro de búsqueda junto a **Servicios** , busque y seleccione **CloudWatch**.
- En el panel de navegación izquierdo, elija **Todas las alarmas**.

Se mostrarán dos alarmas. El grupo de escalado automático creó estas alarmas de forma automática. Dichas alarmas mantendrán la carga promedio de CPU cerca del 60 % y, al mismo tiempo, respetarán la limitación de tener entre dos y seis instancias.

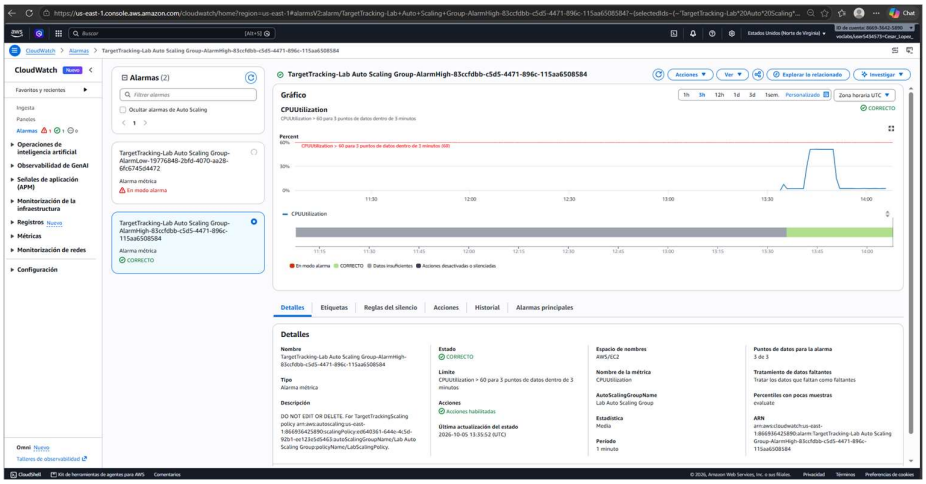


- Seleccione la alarma **OK**, que en su nombre contiene *AlarmHigh*.

Si en ninguna alarma aparece **OK**, espere un minuto y seleccione Actualizar en la esquina superior derecha, hasta que cambie el estado de la alarma.

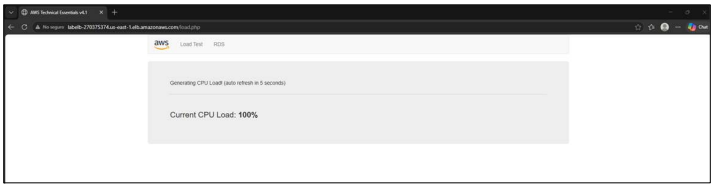
OK indica que la alarma *no* se ha activado. La alarma **CPU Utilization > 60** (Uso de CPU > 60) agrega instancias cuando el uso promedio de CPU es alto. En este momento, el gráfico debería mostrar niveles muy bajos de uso de CPU.

Ahora, le indicará a la aplicación que realice cálculos que deberían aumentar el nivel de uso de CPU.



- Regrese a la pestaña del navegador donde se encuentra la aplicación web.
- Seleccione **Load Test** (Prueba de carga) junto al logotipo de AWS.

Esto hará que la aplicación genere cargas elevadas. La página del navegador se actualizará de forma automática para que todas las instancias del grupo de escalado automático generen carga. No cierre esta pestaña.

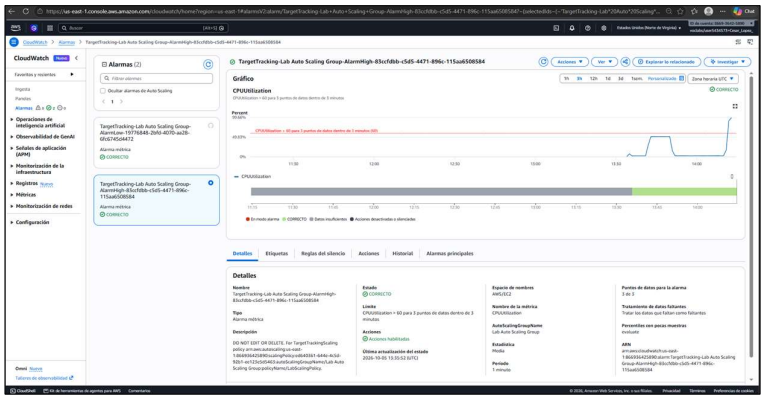


- Regrese a la pestaña del navegador donde se encuentra la consola de **CloudWatch**.

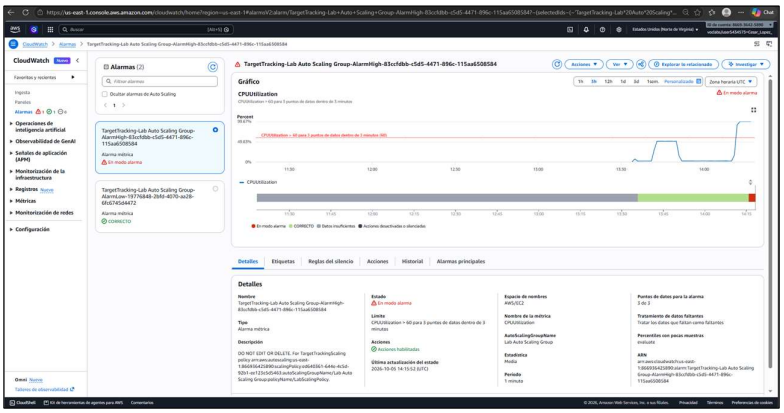
En menos de 5 minutos, la alarma **AlarmLow** debería cambiar a **OK** y el estado de la alarma **AlarmHigh** debería cambiar a *Con alarma*.

Puede seleccionar Actualizar en la parte superior derecha cada 60 segundos para actualizar la pantalla.

Debería ver en el gráfico **AlarmHigh** un porcentaje en aumento del uso de CPU. Cuando se cruce la línea del 60 % por más de 3 minutos, Auto Scaling agregará más instancias.



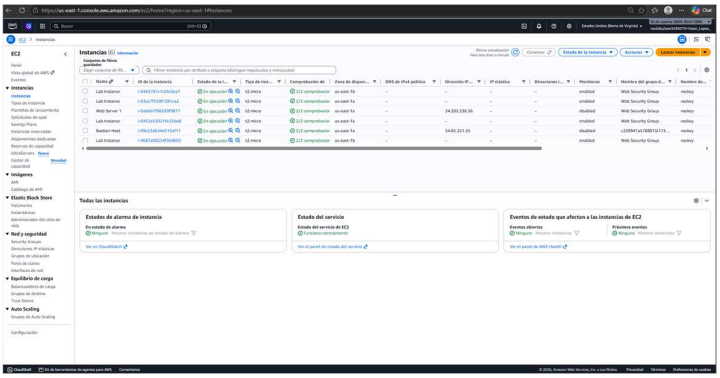
- Espere hasta que la alarma **AlarmHigh** entre en estado *Con alarma*.



Ahora puede visualizar las instancias adicionales que se iniciaron.

- En el cuadro de búsqueda junto a **Servicios** , busque y seleccione **EC2**.

En el panel de navegación izquierdo, elija **Instancias**. Debería haber más de dos instancias etiquetadas como **Lab Instance** (Instancia de laboratorio) en ejecución. Las instancias nuevas se crearon con Auto Scaling como respuesta a la alarma de CloudWatch.

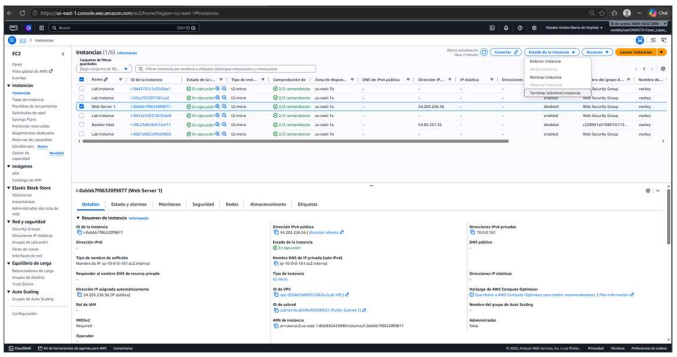


Tarea 6: terminar el Servidor web 1

En esta tarea, terminará el *Web Server 1* (Servidor web 1). Esta instancia se utilizó para crear la AMI que usó el grupo de escalado automático, pero ya no es necesaria.

- Seleccione **Web Server 1** (Servidor web 1) y asegúrese de que sea la única instancia seleccionada.

- En el menú **Estado de la instancia** , seleccione **Estado de la instancia** > **Terminar instancia**.



- Seleccione **Terminar**

